MiniRocket AnomalyDetection LogisticRegression Classification Edge AI Lightweight

자율주행 전기차 모터-감속기 이상 탐지 기술 경량화

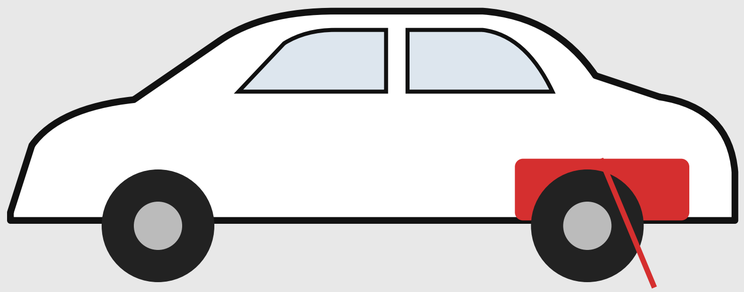
Lightweighting of Anomaly Detection Models for Motor-Reducer Systems in Autonomous Electric Vehicles

C321027 박세진
C321028 박솔

2026.11

연구 개요

— 자율주행 전기차



모터-감속기 (IONIQ, KONA, NIRO)

구동계의 고장을 신호로 감지한다

신호 수집 ›

— 센서 신호

모터 전류



모터 진동



감속기 진동



10초 단위로 측정한 센서 3종 신호

상태 분류 ›

— 고장 진단

정상

편심 주의

편심 결함

감자 결함

감속기 기어 결함

5가지 상태 중 하나로 판정한다

본 연구는 센서 신호를 받아 고장 상태를 분류하는 모델을 차량 제어기 안에서 구동하는 것을 목표로 한다

선행연구의 한계

선행연구 파이프라인

AI Hub - Base Line Model

전류, 진동 신호
모터-감속기

STFT PNG
2000×1280 고해상

DeepLabV3+
ResNet-50 기반 분할모델
GPU 서버급 · 4,200만 파라미터 · 160.5MB

99.6%
Accuracy mIoU 0.99

차량 MCU에 들어갈까?

1 모델 크기

160.5MB / MCU 한도 12.3MB

약 13배 초과

2 연산량 (1회 판단에 필요한 계산량)

약 1,700 GFLOPs / MCU 한도 약 6 GFLOPs

약 280배 초과

3 실행 메모리

약 30MB 이상 / MCU 한도 1.5MB

약 20배 이상 초과

차량에 넣으려면 크기, 연산량, 메모리를 모두 MCU 한도 아래로, 최소 13배에서 최대 280배까지 줄여야 한다

기타 연구

연구 제목	저자 및 연도	성능	사용 모델
Fault Diagnosis of EV Motor-Reducer Using High-Res Spectrogram	박병준, 한동석 (2024)	99.63%	**DeepLabV3+: 모델이 무거움**
Fault Diagnosis of In-wheel Motor EVs Using LSTM	이재훈 외 (2025)	98.7%	**LSTM: NPU가속이 어려움**
Deep Learning-based Instantaneous Fault Diagnosis	김형민 외 (2022)	99.1%	**CNN: 연산량이 크고 메모리 많이 사용**

경량화 필요

연구배경

1 진단이 통신에 의존한다

통신 장애 [1]

국내 커넥티드카 614만 대(2022).
통신사와 데이터센터 장애 시 원격 기능이 중단된 사례가 있다

외부 공격 [2]

2015년 지프 체로키가 통신망을 통한 원격 침입으로 차량 제어 권한을 탈취당하였으며, 140만 대가 리콜되었다

규제 [3]

2025년 8월부터 국내 신차에 사이버보안 인증이 의무화되었다 (UN R155 수준)

통신 단절 시 서버 진단도 중단된다

2 차량 제어기 내부 진단

진단 모델을 제어기(ECU)에 탑재하면
통신 상태와 무관하게 감시가 유지된다

전자 제어 장치(Electronic Control Unit, ECU)

MCU 칩 (연산 장치)
진단 모델의 실행 위치

센서 입력 | 전원 회로 | CAN 통신

MCU의 연산 자원은 PC보다 제한적이다

3 탑재 기준: 차량용 MCU

클럭	**300MHz**
저장 공간 (Flash)	**약 12.3MB**
메모리 (RAM)	**약 1.5MB**

비교: 라즈베리파이 4 [4]

1.5GHz × 4코어, RAM 1~8GB

MCU의 클럭은 약 1/5, 메모리는 수백~수천 분의 1 수준이다

모델은 이 자원 제약을 충족해야 한다

[1] 뉴스토마토, 「커넥티드 카 600만 시대…망 끊기면 무용지물」, 2022.10.17 (과기정통부 통계 인용)
[2] Computerworld, 「Chrysler recalls 1.4M vehicles after Jeep hack」, 2015.07.24
[3] 바이라인네트워크, 「자동차 보안 의무화 시행」, 2025.08.13 (자동차관리법 개정, 2025.08.14 시행)
[4] Raspberry Pi 4 (BCM2711, Cortex-A72 1.5GHz × 4)

데이터 개요

AI Hub 자율주행 고장진단 데이터

550,800건 STFT 스펙트로그램 PNG

총 측정 시간 약 510시간 (약 21일)

한 장의 길이	10초 측정 횟수	차종당	조합당 균등
10초	183,600회	약 1주일치	12,240장 (불균형 없음)

이미지 1장은 단일 차종, 단일 센서, 단일 상태의 10초 측정값이다

차종 3	×	센서 3	×	상태 5	=	45개 조합
IONIQ, KONA, NIRO		모터 전류, 모터 진동, 감속기 진동		정상 1, 결함 4		

결함 유형

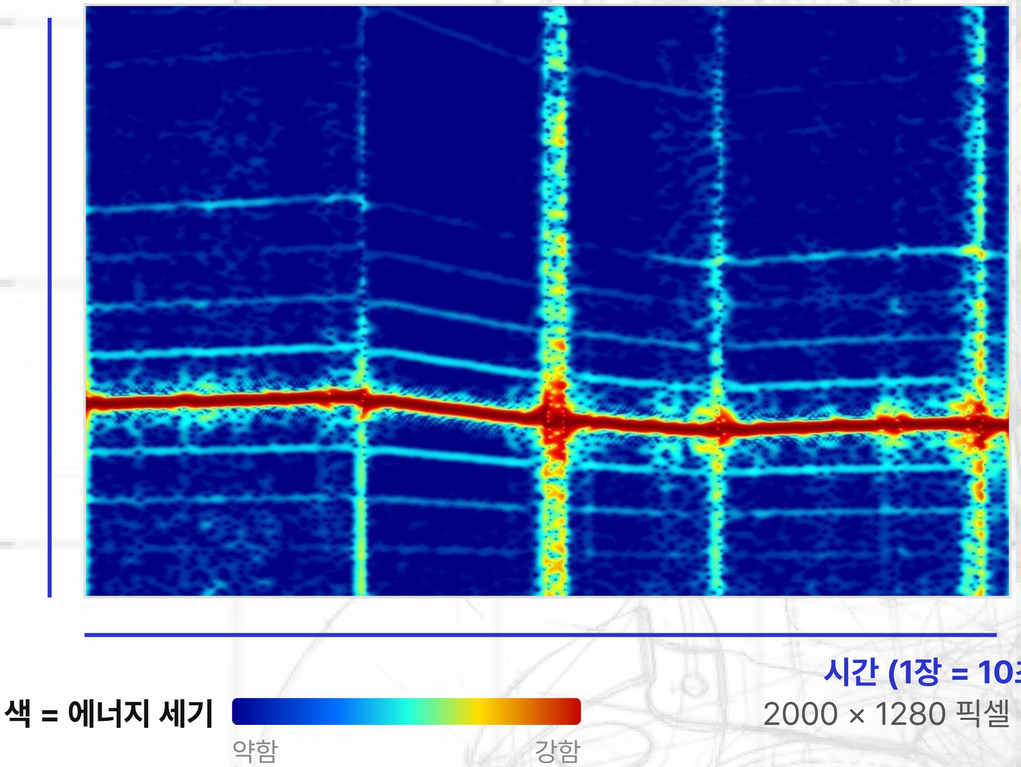
정상	결함이 없는 정상 상태
편심 주의	회전축 중심이 어긋난 상태 (경미)
편심 결함	회전축 중심이 어긋난 상태 (심함)
감자 결함	영구자석의 자력이 감소한 상태
감속기 기어 결함	동력 전달용 감속 기어가 손상된 상태

센서 유형

모터 전류 (U상)	모터 3상 전류 중 U상 전류를 측정한다
모터 진동	모터의 수직 방향 가속도를 측정한다
감속기 진동	감속기의 수직 방향 가속도를 측정한다

STFT 스펙트로그램이란

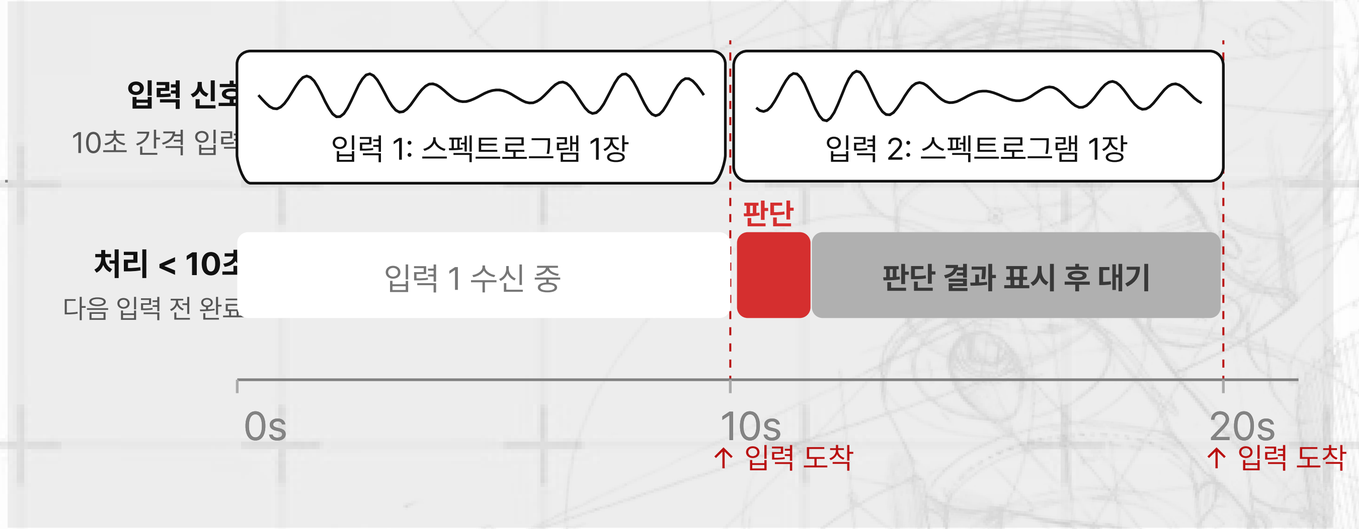
진동 및 전류 신호를 구간별로 분할해 주파수 성분의 크기를 계산(STFT)한다
시간, 주파수, 세기 정보를 단일 영상에 표현하여 결함별 패턴 비교가 가능하다



연구 방법

- **정확도** ····· 베이스라인 모델 수준
- **모델 크기** ····· MB 단위
- **추론시간** ····· <10초

10초의 근거



— 데이터 준비 (이미지의 시계열 변환)

01 센서 신호
모터 전류, 모터 진동,
감속기 진동 (센서 3종)

02 스펙트로그램 PNG
가로축 시간, 세로축 주파수
10초당 1장 (AI Hub)

03 특징 추출
시점마다 센서당
특징 29개 추출

04 다변량 시계열
87채널 × 2,000시점
(CSV로 저장)

— 경량 모델 (시계열 기반 고장 판정)

05 MiniRocket 변환
시계열 → 숫자 9,996개
(패턴 빈도 벡터)

06 로지스틱 회귀
정상, 편심 2종,
감자, 기어 (5상태 판정)

— 배포 (저사양 장치 실행)

07 엣지 추론
라즈베리파이 4
10초 이내 판정

08 대시보드
판정 결과
실시간 모니터링

데이터 경량화

— 경량화 효과를 저장 용량, 판정 1회 입력, 모델 크기로 구분하여 비교한다

1 저장 용량 (전체 데이터)

약 940GB → **약 128GB** **-86%**

PNG 550,800장 × 평균 1.71MB → 시계열 183,600회 × 0.70MB

학습 전처리 시간과 디스크 사용량이 감소한다.
판정에는 10초 분량만 사용되므로 판정 속도와는 무관하다

2 판정 1회 입력 (10초, 센서 3종)

5.1MB → **0.70MB** **-86%**

PNG 3장(값 2,304만 개) → 87채널 × 2,000시점(값 17.4만 개, 1/132)

장치가 10초마다 처리하는 값이 1/132로 감소하여
메모리 사용량과 연산량이 줄어든다

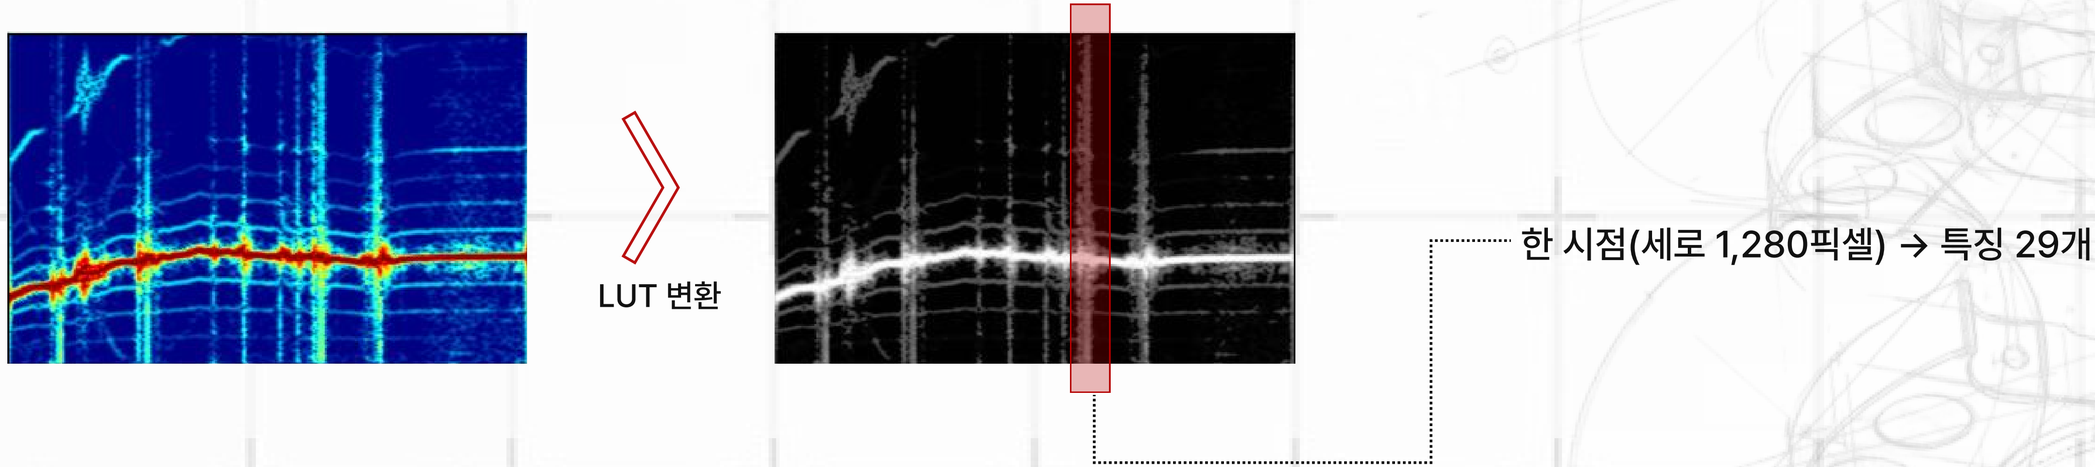
3 모델 크기 (3차종 합계)

45.17MB → **2.07MB** **-95%**

AI Hub 공개 DeepLabV3+ → MiniRocket + 로지스틱 회귀 (차종당 0.69MB)

3차종 모델(2.07MB)을 저사양 장치 메모리에 함께 적재할 수 있다

차량 탑재에 영향을 주는 요인은 판정 1회 입력과 모델 크기의 감소이며, 저장 용량 감소는 부수적 효과이다



학습 방법

87채널 시계열 → MiniRocket 변환 → 숫자 9,996개 → 로지스틱 회귀 → 5가지 상태 판정

센서
- 모터 전류(U상) 29피처
- 모터 진동 29피처
- 감속기 진동 29피처

→ 87피처

차종
- IONIQ
- KONA
- NIRO

→ 분류 모델 3개

MiniRocket

A Very Fast (Almost) Deterministic Transform for Time Series Classification

Rocket

수많은 무작위 합성곱(Convolutional) 커널을 사용해 시계열 데이터를 특징 벡터로 변환한 뒤,
간단한 선형 분류기에 통과시켜 빠르고 정확하게 분류하는 알고리즘

MiniRocket

무작위 컨볼루션 커널을 작고 고정된 결정론적 커널 세트로 대체하여 Rocket을 재구성
→ 무작위성을 크게 줄이고 상당한 속도 향상을 가능하게 함

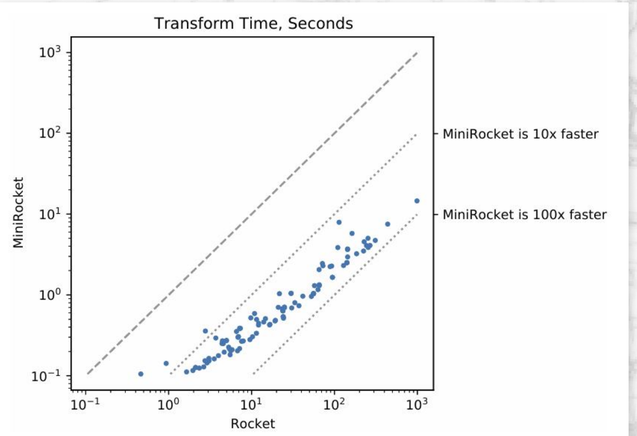


Figure 2: Transform time for MiniRocket versus Rocket for the same 109 datasets from the UCR archive.

학습 방법

— 87채널의 구성: 센서별 특징 29개 × 센서 3종

특징 묶음	개수	담은 정보 (시점마다 계산)
기본 특징	**4**	최대 에너지 주파수 위치, 에너지 분포 대역의 시작과 끝, 신호 세기(RMS)
회전수	**1**	모터 회전 속도(rpm)
에너지 분포 (주파수축)	**12**	8개 주파수 대역별 에너지 비율, 무게중심(에너지의 평균 주파수), 엔트로피(에너지 분산 정도), 롤오프(누적 에너지 85% 지점), 평탄도(특정 주파수로의 에너지 집중 정도)
에너지 분포 (차수축)	**12**	위 12개를 '주파수 ÷ 회전수' 기준으로 다시 계산한다. 회전수가 달라도 결함 성분 위치가 같게 나타난다
센서 1종 합계	**29**	**× 센서 3종(모터 전류, 모터 진동, 감속기 진동) = 87채널을 단일 모델에 입력**

왜 87채널인가

특징 묶음을 하나씩 추가하며 비교한 결과, 87채널의 Macro-F1이 가장 높았다 (주행 단위 3-fold 교차검증, 3차종 평균)

15채널 (기본+회전수)	51채널 (+주파수축 분포)	87채널 (+차수축 분포)
0.881	**0.964**	**0.973**

— 로지스틱 회귀 선택 근거

1 MiniRocket은 선형 분류기와의 결합을 전제로 설계되었다

MiniRocket이 시계열을 특징 9,996개로 변환하면, 분류기는 이들의 가중합만 계산한다. 원 논문 역시 변환 결과를 선형 분류기로 판정한다

Dempster et al. (2020, 2021) ROCKET / MiniRocket

2 5가지 상태별 확률을 출력한다

대시보드의 이상 점수는 100에서 정상 확률(%)을 뺀 값이다. 확률을 출력하지 않는 분류기로는 이 점수를 산출할 수 없다

3 추론 속도가 빠르고 모델 크기가 작다

라즈베리파이 4에서 분류 단계는 1.57ms로 전체 판정 시간(455ms)의 0.35%이다. 변환기와 분류기를 포함한 모델 크기는 차종당 0.69MB이다

엣지 실측, 차종별 모델 3개(IONIQ, KONA, NIRO)

Behind the Scenes

최종 모델이 만들어지기까지

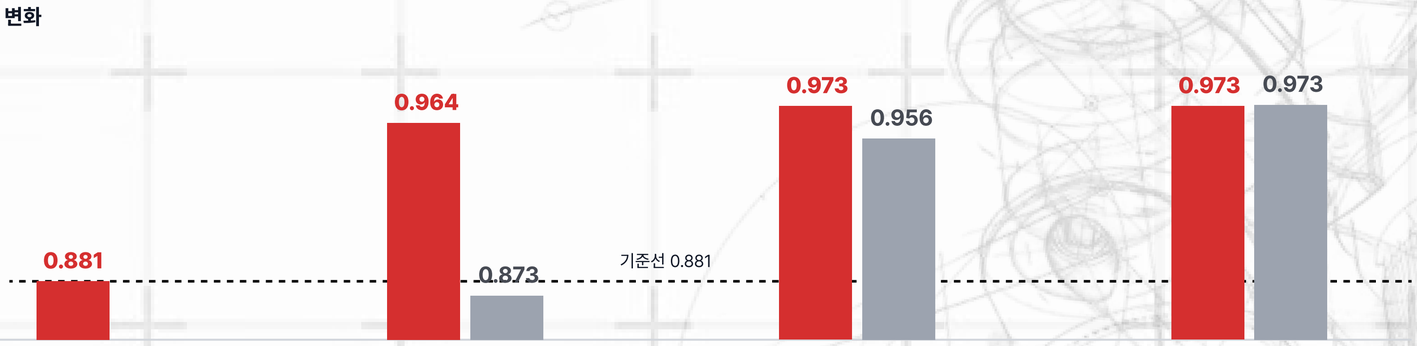
원칙: 특징은 실험 전에 정한 출처에서만 도출하고, 한 묶음씩 추가하여 사전에 정한 기준으로 채택 여부를 판정한다

채택한 구성 (가운데 경로)

같은 단계에서 비교한 뒤 기각한 대안 (아래 흰 점선)

막대 높이는 Macro-F1 (3차종 평균, 주행 단위 3-fold)

Macro-F1 변화



출발점
원본 스펙트로그램 PNG
2000×1280 픽셀, 센서별 10초당 1장

1단계
시계열 특징 변환
시점별 특징 추출
판정 1회 입력 1/132

기각
이미지 입력 딥러닝
DeepLabV3+ 45.17MB
MCU 탑재 기준 초과

2단계
센서 3종 융합 + 회전수
15채널, 단일 모델
Macro-F1 0.881 (기준선)

기각
센서별 개별 모델
모델 9개 필요
(센서 3종 × 차종 3종)

3단계
+ 범용 스펙트럼 통계
51채널
DEMAG 재현율 +12.4~15.8%p

기각
+ 인버터 온도
18채널, Macro-F1 0.873
전 차종 하락

4단계
+ 차수축 특징
87채널
DEMAG 재현율 0.928 → 0.955

기각
차수축만 사용
51채널, Macro-F1 0.956
결합 구성보다 낮음

최종
87채널 MiniRocket
+ 로지스틱 회귀
차종별 모델 3개, 각 0.69MB

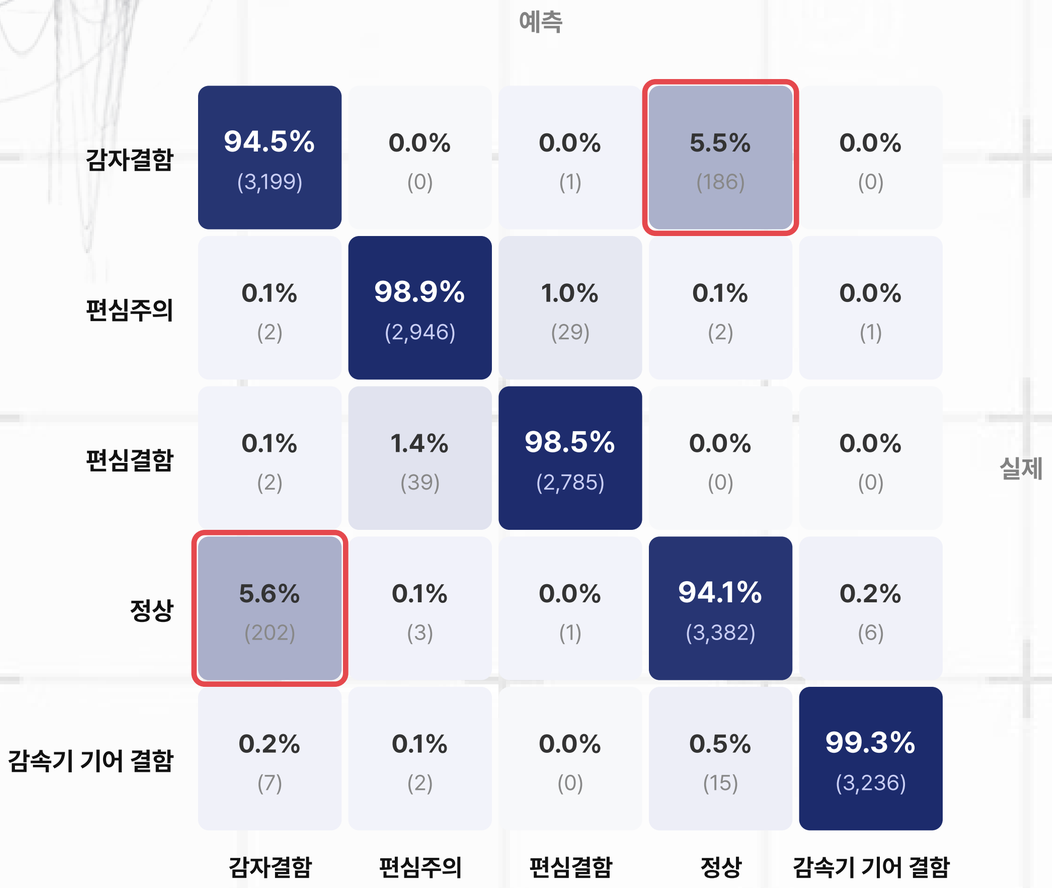
기각
+ 메타데이터 25개
+0.058%p, 95% CI가 0 포함
유의한 개선 없음

판정 기준 (실험 전 고정)

채택 DEMAG 재현율 +3%p 이상 **메타데이터** Macro-F1 95% CI가 0 초과 **평가** 주행 단위 3-fold 교차검증

최종 모델 성능

혼동행렬



오분류 구성



감자결함 ↔ 정상	388건 (77.9%)
편심주의 ↔ 편심결함	68건 (13.7%)
기타	42건 (8.4%)

정확도
96.90%

macro-F1
97.06%

정답 수
15,548 / 16,046

오답 수
498건

BaseLine Model과의 비교

비교 전 BaseLine 모델의 데이터 누수 제거

기존 평가: 무작위 분할



- 10초 조각을 무작위로 8:1:1로 분리
- 같은 세션의 조각이 학습·테스트 양쪽에 포함
- 테스트 측정 1,066개 중 **1,063개(99.72%)**가 학습에도 포함

공정 평가: 세션 단위 분할



- 측정 세션째로 학습·검증·테스트 분리
- 세션 중복은 **0개**이다
- 학습에 사용되지 않은 주행으로만 평가
- 두 모델 모두 동일한 학습 626세션, 테스트 391세션 사용

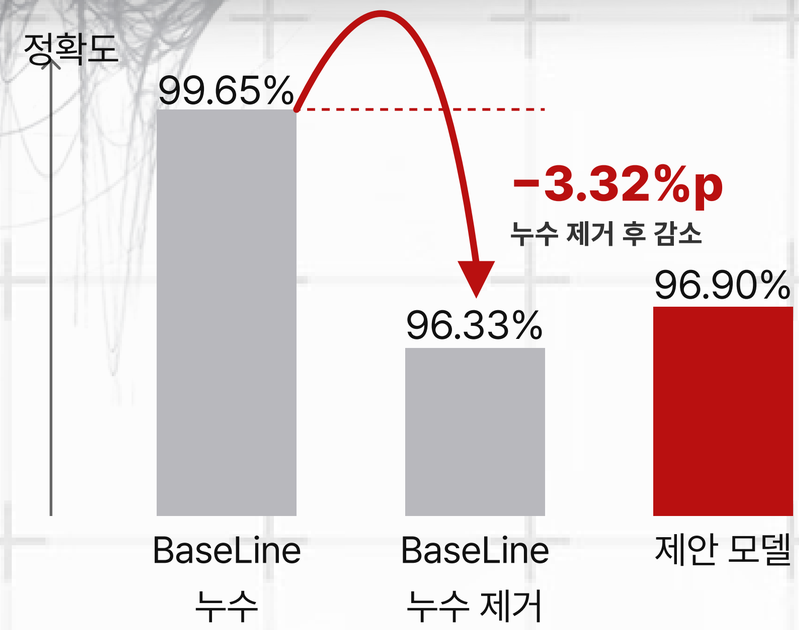
BaseLine 모델 정확도

99.65%

누수 제거한 BaseLine 모델 정확도

96.33%

BaseLine Model과의 비교

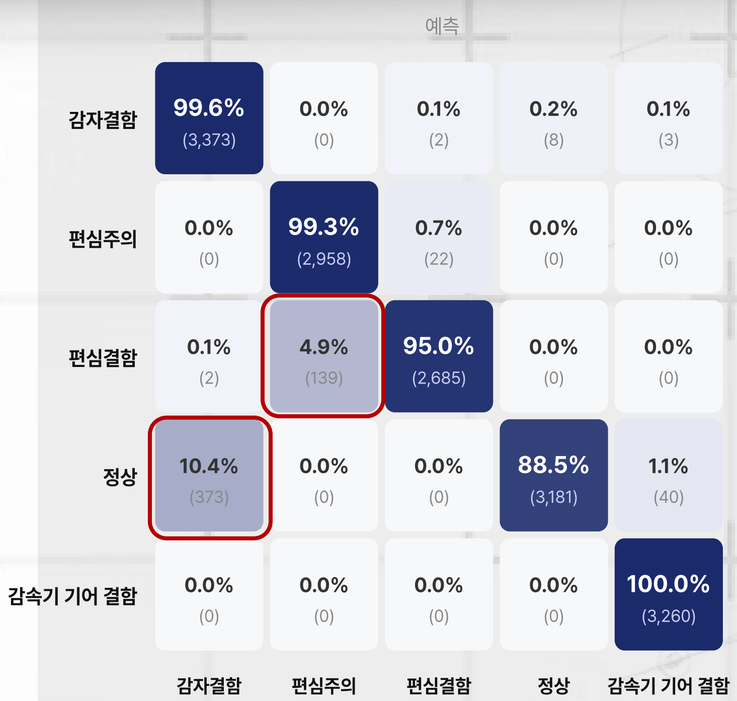


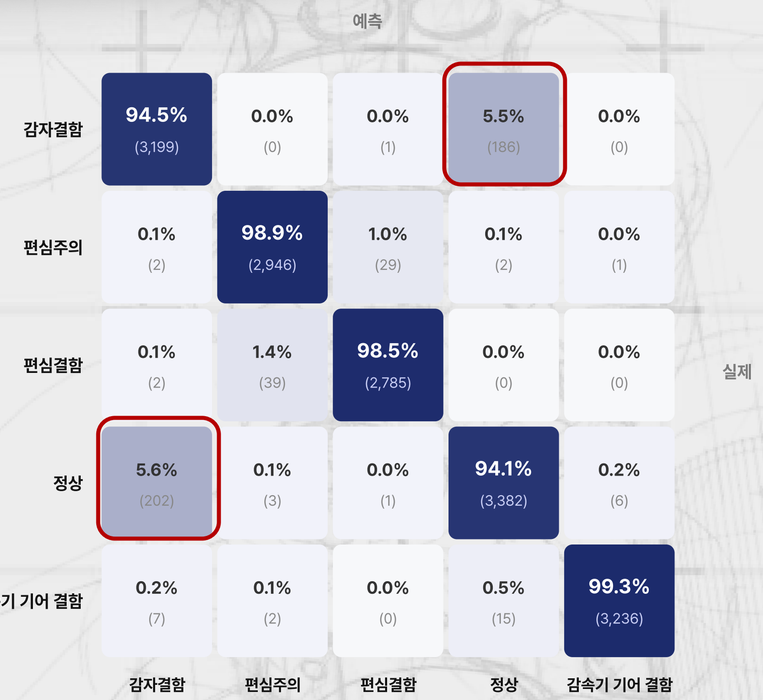
H_0 제안 모델 정확도 = BaseLine 모델 정확도

H_1 제안 모델 정확도 ≠ BaseLine 모델 정확도

p-value **p = 0.288 > 0.05**

∴ **두 모델의 정확도 차이는 통계적으로 유의하지 않았다**





BaseLine 모델 → **제안 모델**

감자결함 ↔ 정상 **0.1%p 증가**

편심주의 ↔ 편심결함 **1.6%p 감소**

엣지 환경 구동 검증

Raspberry Pi 4 실측 결과

지연 구성

▶ 시작: 87채널 입력 준비 완료 **455.02ms** ■ 종료: 5클래스 확률, 이상 점수 출력



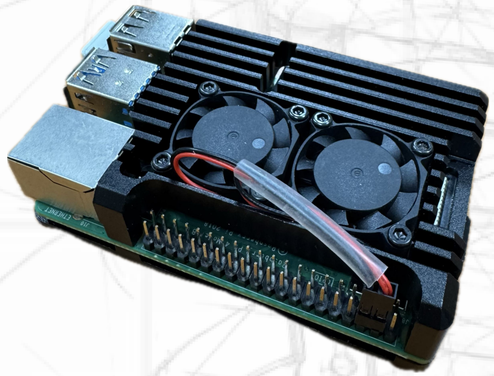
전처리 1.35ms (0.30%)

분류기 1.57ms (0.35%)

※ 막대 길이는 소요 시간에 비례하지 않는다

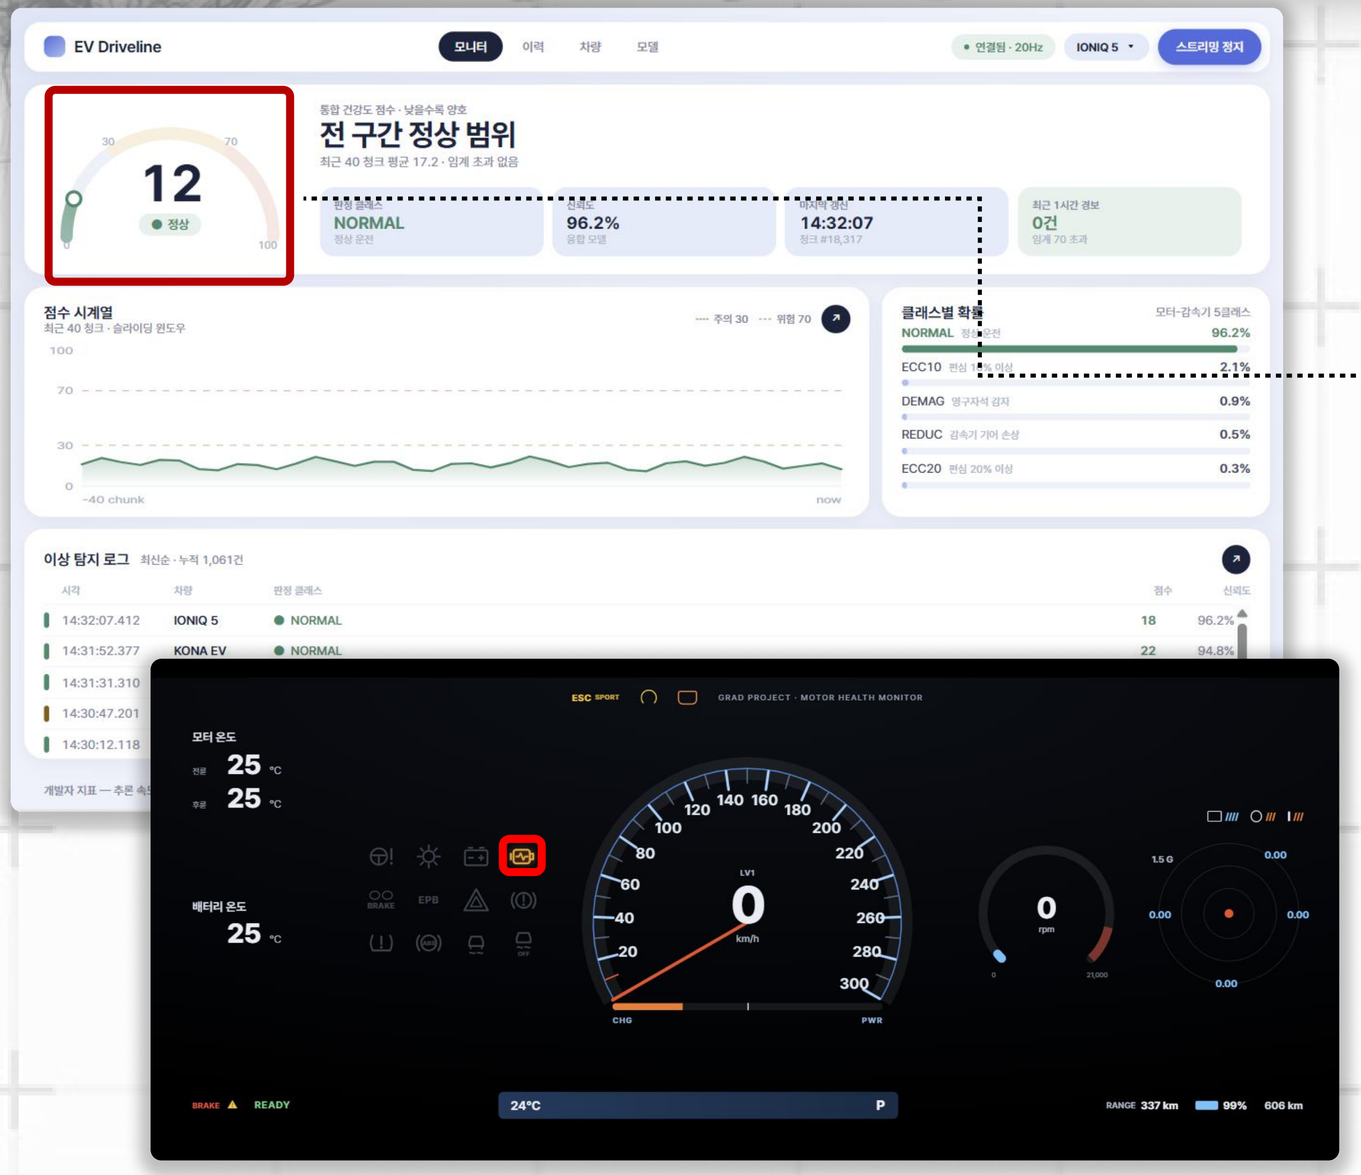
판정 지연 **455ms (목표의 약 4.6%)**

목표 10초 10,000ms



판정 지연: 87채널 입력 준비 시점부터 판정 결과 출력까지의 시간

대시보드, 계기판



대시보드

- 정비사의 점검과 진단을 지원한다
- Anomaly Score: 1-P(Normal)

정상 0~30
주의 30~70
결함 70~100

계기판

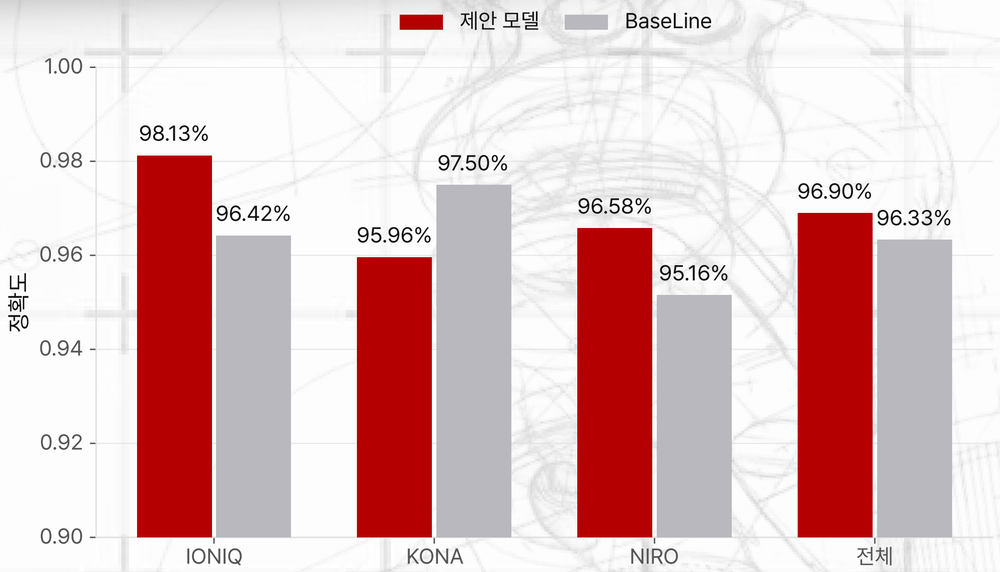
- 운전자에게 차량 상태 정보를 제공한다
- 주의 분산 방지를 위해 이상 발생 시에만 강조 표시한다

회색: 정상, 주황: 주의, 빨강: 결함

결론

	베이스라인 모델	제안 모델	차이
입력 경량화(10초)	약 23MB	약 0.7MB	약 1/33
정확도 유지	96.33%	96.90%	−0.43 ~ +1.62%p
모델 경량화	45.17MB	2.17MB	−95.2%

정확도는 96.33%에서 96.90%로 유지되었으며
입력은 약 1/33, 모델 크기는 95.2% 감소하였다



3개 차종 중 2개(IONIQ, NIRO)에서 제안 모델의 정확도가
베이스라인 모델보다 높았고, KONA에서는 낮았다
(전체: 제안 모델 96.90%, 베이스라인 모델 96.33%)

향후 개선 방향

1 센서 데이터의 STFT 변환 시간 측정

센서 신호 수신부터 단시간 푸리에 변환(Short-Time Fourier Transform, STFT)
및 특징 추출까지의 소요 시간을 측정한다. 현재 측정값 455ms는
변환 이후 구간이므로, 전체 지연이 10초 이내인지 확인할 계획이다.

2 실차 적용 가능성 검증

실제 차량용 MCU(Flash 12.3MB, RAM 1.5MB)에 모델을 이식하여
동작과 지연을 검증한다. 실차 주행 데이터에서 정확도가
유지되는지 확인할 계획이다.